

Wi-Fi 測位モデルの経年劣化に特化した異常検知手法

山本 晃平（立命館大学）, 坪内 孝太（ヤフー株式会社）, 西尾 信彦（立命館大学）

1 背景

Fingerprinting 測位で使用する測位モデルは環境の変化などにより劣化する。追加の Labeled Fingerprint (LF: 位置情報を持つ Fingerprint) を遷移学習して劣化を抑える手法 [1] があるが、収集点の選定はランダムのため回復率が低くなる。本研究では、位置情報サービスから自動収集される Unlabeled Fingerprint (UF: 位置情報を持たない Fingerprint) を解析して電波変化が起きた収集点を異常として検知することで、より高い回復率での測位モデルの更新を実現した。

2 測位モデルの遷移学習

本研究は、測位モデルの遷移学習に用いる手法に依存しないフレームワークを目指しており、提案する異常検知手法を代表的な 2 種類の遷移学習である MixTrain 手法と Lasso 手法に対して適用することでその有効性を示す。MixTrain 手法は、測位モデルのパラメータの重みそのものを学習する手法で、L1 ノルムの制約化項 ($\sum_{i=1}^{|\theta|} |\theta_i|$) を加えることで特徴量 θ の重みがオーバフィッティングすることを防ぐ。Lasso 手法は、パラメータの変化量を学習させる手法で、L1 ノルムで学習を行いその制約化項は $\sum_{i=1}^{|\theta|} |\theta_i^{(k-1)} - \theta_i^{(k)}|$ であり、 $k-1$ 期目のパラメータ θ と k 期目のパラメータ θ の差分が小さくなるような制約化を行う。

3 異常検知を含む測位モデル更新プロトコル

本研究で提案する異常検知手法は、各 AP を他の AP との相対的な距離を示すベクトルモデルで表現し、電波変化が起きた AP 付近の収集点で LF を再収集して遷移学習に使用する。まず、式 (1) を満たす UF を解析対象とする。 R は観測された BSSID で r はその RSSI, $vecFilt$ は任意の RSSI の閾値を示している。次に、式 (2) に基づき、任意の AP A の近くで観測された尤度が高い UF を $vecWidth$ の範囲で AP A に関してのベクトルモデルとして表現する。そして、次に当該 AP のベクトルモデル A' が作成された際、式 (3) に示されるベクトルモデル A とのコサイン類似度を用いて異常な AP を検出する。

$$(R_{1r1}, R_{2r2}, R_{3r3}, \dots, R_{rxrx}) \{vecFilt < \max(r1, rx)\} \quad (1)$$

$$\vec{A} = (R_{1r1}, R_{2r2}, R_{3r3}, \dots, R_{rxrx}) \{vecFilt < \max(r1, rx), vecWidth < rx\} \quad (2)$$

$$\cos(\vec{A}, \vec{A}') = \frac{\vec{A} \cdot \vec{A}'}{|\vec{A}| |\vec{A}'|} = \frac{\vec{A} \cdot \vec{A}'}{|\vec{A}| \cdot |\vec{A}'|} = \frac{\sum_{i=1}^{|\vec{A}|} A_i A'_i}{\sqrt{\sum_{i=1}^{|\vec{A}|} A_i^2} \cdot \sqrt{\sum_{i=1}^{|\vec{A}'|} A_i'^2}} \quad (3)$$

最後に、異常判定された AP を強く観測していた UF について、AP A の電波を無視して測位し、当該 AP が存在すると考えられる重心を加重平均で算出してその付近の収集点での LF を遷移学習に用いる。

4 有効性検証

図 1 は、AP の移設により電波変化を再現し、移設した 6 つの AP と移設していない 18 つの AP のベクトルモデルの類似度を算出した結果である。縦軸は類似度を、移設した AP については移設した距離を横軸に示している。結果より、異常な AP と正常な AP の類似度には大きな差が確認された。図 2 は、大阪の地下街において 4615m² を対象測位エリアと




図 1: AP の移設実験における各ベクトルモデルの類似度

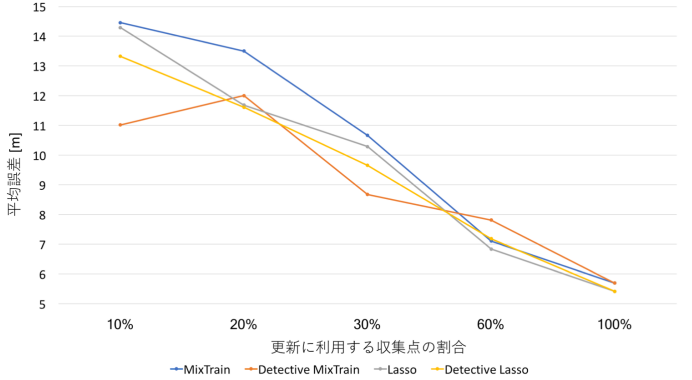


図 2: 遷移学習に用いる収集点の割合による平均誤差

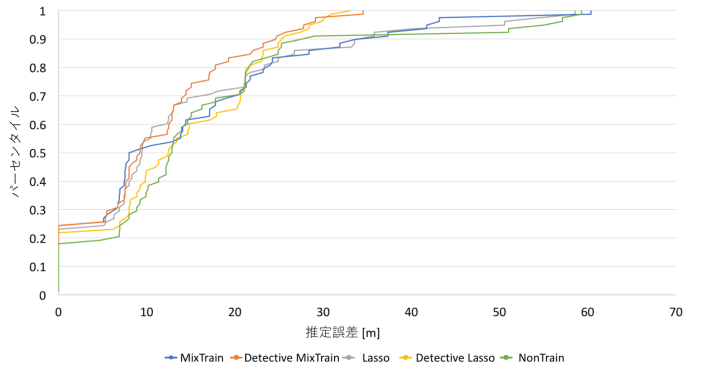


図 3: 各手法の推定誤差の累積分布 (10%サンプリング時)

し、5ヶ月分の LF/UF を用いて、最終的な測位モデルの平均誤差を縦軸として算出した結果を示している。横軸はモデルの更新に使用した収集点の割合であり、MixTrain 手法および Lasso 手法に異常検知を組み合わせたものを Detective と記述している。図 3 は、図 2 における 10%サンプリング時の位置推定誤差の累積分布をプロットしたものである。一度もモデルの更新をしていない NonTrain 手法もベースラインとして掲載している。図 2 および図 3 の結果から、提案手法を既存の 2 種類の遷移学習 MixTrain 手法・Lasso 手法による測位モデルの更新に適用したところ、MixTrain 手法においては最大で 76.2%まで、Lasso 手法においては最大で 93.3%まで測位モデルの劣化の抑制を実現した。

参考文献

- [1] Bin Yang et al. Localization algorithm in wireless sensor networks based on semi-supervised manifold learning and its application, Cluster Computing, Vol. 13, No. 4, pp. 435–446 (2010).